



SAPIENZA
UNIVERSITÀ DI ROMA

Università Sapienza, Roma

Facoltà di Lettere e Filosofia, Ingegneria dell'Informazione, Informatica e
Statistica
Dipartimento di Filosofia

Laurea in Filosofia e Intelligenza Artificiale
Relazione per l'esame di Intelligenza Artificiale II

“Analisi predittiva della copertura sanitaria pubblica”
Applicazione della regressione logistica e valutazione della fairness

Ilaria Bottani - Matricola: 2154959

bottani.2154959@studenti.uniroma1.it

Claudia De Rossi - Matricola: 1992222

derossi.1992222@studenti.uniroma1.it

Professoressa: Flavia Monti

Sommario

Il progetto prende in esame il tema dell'equità algoritmica applicata a un modello di previsione della copertura sanitaria pubblica in California durante l'anno 2019. L'obiettivo è addestrare una regressione logistica per stimare l'accesso ai servizi e verificare se il modello generi o aumenti disparità basate su fattori sensibili come sesso, etnia, età e disabilità. Il lavoro studia inoltre la natura di queste disparità, distinguendo tra quelle spiegabili da fattori socio-economici o normativi e quelle potenzialmente discriminatorie. Infine, viene effettuata una valutazione predittiva del modello attraverso l'analisi di metriche di valutazione quali: Precision, Recall, F1-score e ROC-AUC e metriche di fairness.

1. Definizione del contesto

Il crescente utilizzo di sistemi di Intelligenza Artificiale nel supporto alle decisioni pubbliche solleva questioni critiche circa l'equità algoritmica (*fairness*). Il problema centrale risiede nel fatto che i modelli predittivi, se addestrati su dati storici che riflettono disparità strutturali, tendono non solo ad apprendere, ma a perpetuare tali ingiustizie, svantaggiando sistematicamente minoranze etniche e/o gruppi vulnerabili. In questo studio, esaminiamo un modello di classificazione volto a predire l'accesso alla copertura sanitaria pubblica in California, utilizzando i dati del Census Bureau (ACS 2019).

La domanda che guida la nostra analisi è: *in che misura le disparità presenti nei dati storici influenzano le prestazioni di un modello di regressione logistica e quali implicazioni etiche emergono dalla valutazione della sua fairness in assenza di tecniche di de-biasing?*

Per rispondere, procediamo prima a quantificare le disparità presenti nei dati grezzi, per poi confrontare le performance del modello base con le tecniche di valutazione e fairness.

2. Descrizione del Dataset

Il dataset oggetto di studio è tratto dall'**American Community Survey (ACS) - anno 2019**, specifico per lo Stato della California, un'indagine condotta annualmente dallo U.S. Census Bureau e ottenuta tramite la libreria folktabs. Esso si propone di classificare la **copertura sanitaria pubblica** (target: PUBCOV), identificando se un individuo sia beneficiario di programmi assistenziali. Il campione analizzato si compone di 131,748 osservazioni e 19 variabili.

Le variabili (feature) includono indicatori socio-demografici ed economici fondamentali come: il livello di istruzione (SCHL), lo stato civile (MAR) e il reddito personale (PINCP), tuttavia, particolare attenzione è destinata alle variabili sensibili, in particolare l'appartenenza etnica (RAC1P), l'età (AGEP), il sesso (SEX) e la presenza di disabilità (DIS), poiché esse risultano fondamentali per indagare potenziali disparità sistemiche.

Infine, il dataset è stato pre-filtrato per restringere lo studio ad individui con età inferiore ai 65 anni. Questa scelta metodologica isola il fenomeno della copertura pubblica come strumento di *welfare* alle fasce sociali che non godono automaticamente di coperture statali, rendendo l'analisi della *fairness* particolarmente significativa in termini di equità distributiva.

3. Il target

La variabile dipendente (target) del presente studio è la copertura sanitaria pubblica, rappresentata dalla feature **PUBCOV**, un indicatore binario che identifica se un individuo possiede una copertura assicurativa sanitaria pubblica. La scelta ricade su questa variabile poiché essa rappresenta il principale strumento di

protezione sociale per le fasce di popolazione a basso reddito, dimostrandosi il parametro più efficace per valutare l'equità nel sistema sanitario.

La scelta di questo target risponde a una duplice esigenza: se da un lato ci permette di mappare i segmenti di popolazione potenzialmente esclusi dai servizi, offrendo indicazioni preziose per orientare le politiche pubbliche (*policy-making*) in modo più inclusivo, dall'altro, la natura binaria dell'indicatore facilita l'applicazione rigorosa di metriche di equità, consentendoci di indagare se l'allocazione delle risorse sanitarie sia realmente basata sulle necessità o se, al contrario, sia distorta da bias sistemici o variabili correlate a status socio-economici.

4. Analisi Esplorativa dei Dati (EDA)

L'analisi esplorativa dei dati (EDA) si propone di comprendere se esistano disparità intrinseche nelle caratteristiche della popolazione dello Stato della California, poiché tali iniquità potrebbero essere involontariamente apprese o amplificate dall'algoritmo. A tal fine, è stata condotta un'analisi di *bias* finalizzata a verificare se il "tasso di copertura" sia distribuito in modo equo tra i diversi segmenti della popolazione, identificati attraverso variabili sensibili (“sex”, “disability”, “age_group” e “race”).

L'approccio metodologico adottato si articola in due fasi complementari:

- **Analisi quantitativa:** il sistema calcola innanzitutto la media generale del tasso di copertura (*overall_rate*), utilizzandola come *benchmark* di riferimento. Successivamente, il dataset viene segmentato per ogni categoria presente nelle variabili sensibili, generando un prospetto ordinato della copertura di ciascun sottogruppo.

```
--- Tasso di copertura per 'sex' ---
      sex
Female    34.4%
Male      37.3%
Name: PUBCOV, dtype: object

--- Tasso di copertura per 'disability' ---
      disability
Without disability    31.1%
With disability       68.6%
Name: PUBCOV, dtype: object

--- Tasso di copertura per 'age_group' ---
      age_group
18-34         31.6%
35-49         36.2%
0-17          37.5%
50-64         41.1%
Name: PUBCOV, dtype: object
```

```


--- Tasso di copertura per 'race' ---
              race
Asian         27.8%
White         34.5%
Other         36.8%
Hispanic      41.3%
Black         51.4%
Name: PUBCOV, dtype: object

Media generale: 35.6%

```

Questo passaggio permette di quantificare istantaneamente lo scostamento di ogni categoria rispetto alla media globale (35,6%).

- **Visualizzazione diagnostica:** per favorire l'interpretabilità dei risultati e semplificarne la visualizzazione, implementiamo una griglia di grafici a barre che pone a confronto il tasso di copertura dei singoli sottogruppi con la media generale, rappresentata graficamente da una linea rossa tratteggiata.



L'analisi rivela disparità marcate tra i vari attributi considerati, ci troviamo dunque in condizione di chiarire una distinzione metodologica tra semplici variazioni statistiche e veri e propri bias sistemici.

Nel caso di **disabilità** ed **età**, infatti, il divario appare come una forma di *explainable discrimination*. L'elevata copertura osservata tra le persone con disabilità non è dunque sintomo di un'ingiustizia da sanare, bensì il riflesso del corretto funzionamento del sistema di welfare, che destina programmi pubblici mirati a chi necessita di maggior protezione. Analogamente, il gradiente legato all'età risulta fisiologico: l'idoneità ai servizi e il relativo bisogno di assistenza evolvono naturalmente lungo il corso della vita, giustificando le tutele specifiche previste per le fasce anagrafiche più giovani o anziane.

Viceversa, la situazione si complica radicalmente nell'osservazione dell'attributo **etnia**. Qui, la disuguaglianza riscontrata non trova facili giustificazioni funzionali, riflettendo piuttosto probabili dinamiche socio-economiche strutturali e pregiudizi storici profondamente radicati.

5. Preprocessing e Feature Engineering

Nella sezione di preprocessing, prepariamo i dati per l'addestramento separando le variabili sensibili (sensitive) dal dataset di input del modello (X_model). Tale operazione, nota come *Fairness through blindness* (o "equità per cecità"), mira a prevenire il bias diretto eliminando variabili quali **sexso**, **disabilità**, **età** ed **etnia**.

Tuttavia, ne segue necessariamente un approccio critico: la semplice rimozione di tali attributi non garantisce l'assenza di discriminazione. Il dataset infatti, conserva variabili "proxy" come il reddito personale (PINCP) o, laddove presente, la fertilità (FER), feature che mantengono forte correlazione con gli attributi sensibili rimossi, e, poiché il modello può ricostruire le informazioni sensibili attraverso queste correlazioni latenti, il rischio di reintrodurre bias sistemici rimane elevato.

Per quanto riguarda la struttura tecnica, utilizziamo un **ColumnTransformer** per normalizzare le feature numeriche tramite **StandardScaler**, garantendo stabilità algoritmica e applichiamo **OneHotEncoder** alle variabili categoriche per ottimizzarne la rappresentazione.

Il processo in questione trasforma il dataset in una forma idonea alla regressione logistica, pur mantenendo le variabili sensibili separate per permettere un audit di equità rigoroso nelle fasi successive.

6. Regressione logistica e valutazione del modello

Terminata la fase di analisi esplorativa, abbiamo proceduto alla costruzione di un modello capace di prevedere la condizione di copertura sanitaria pubblica (PUBCOV) di un individuo. Per affrontare questa sfida di classificazione binaria, abbiamo optato per un modello di **regressione logistica**.

La scelta è determinata dal contesto specifico: in contesti di analisi socio-sanitaria, la regressione logistica rappresenta un punto di equilibrio ideale tra rigore statistico e leggibilità. Operativamente, l'algoritmo trasforma una combinazione lineare delle variabili esplicative in una funzione sigmoide, traducendo l'output in un valore di probabilità compreso tra 0 e 1, ciò ci permette non solo di assegnare l'individuo a una delle due classi, ma anche di comprendere il grado di certezza associato a tale predizione.

Per garantire l'affidabilità delle nostre inferenze, abbiamo suddiviso il dataset in un *Training set* (80%) per l'apprendimento e un *Test set* (20%) per la validazione. Successivamente, data la prevalenza di una classe rispetto all'altra, abbiamo adottato la tecnica `class_weight='balanced'`, un accorgimento fondamentale per assegnare un peso maggiore agli errori commessi sulla classe minoritaria al fine di impedire al modello di trascurare i casi meno frequenti, nel tentativo di migliorare la capacità di generalizzazione del sistema.

6.1 Analisi delle Prestazioni e Considerazioni sull'Equità

Una volta addestrato il modello, abbiamo sottoposto le sue previsioni a rigorosa valutazione:

```
--- Performance globali ---
  Accuratezza: 0.696
  Precision:   0.664
  Recall:      0.296
  F1-score:    0.409
```

sebbene l'accuratezza globale (69,6%) offra una prima indicazione di efficacia, abbiamo preferito approfondire l'analisi mediante metriche più selettive per cogliere le dinamiche del classificatore.

Dal divario tra Precision (66,4%) e Recall (29,6%) è chiaro come il nostro modello adotti un approccio estremamente conservativo (estremamente prudente nel classificare un'osservazione come positiva), esso infatti, identifica correttamente la classe positiva quando ne è certo, ma tende a essere cauto, omettendo una quota non trascurabile di soggetti che possiedono la copertura sanitaria quando le evidenze nei dati non sono sufficientemente forti da superare la sua soglia di confidenza.

Per quanto riguarda invece le prestazioni disaggregate del modello, esse rivelano una variabilità significativa nelle metriche, evidenziando come l'accuratezza non sia distribuita in modo uniforme tra i diversi sottogruppi della popolazione:

```
--- Performance per 'sex' ---
      accuratezza  precision  recall    f1
sex
Female           0.672      0.516   0.579  0.546
Male             0.641      0.521   0.613  0.563

--- Performance per 'disability' ---
      accuratezza  precision  recall    f1
disability
With disability    0.706      0.735    0.9   0.809
Without disability 0.652      0.445    0.5   0.471

--- Performance per 'age_group' ---
      accuratezza  precision  recall    f1
age_group
0-17             0.653      0.536   0.708  0.610
18-34             0.637      0.434   0.492  0.461
35-49             0.664      0.534   0.567  0.550
```

50-64	0.692	0.604	0.703	0.650
-------	-------	-------	-------	-------


```

--- Performance per 'race' ---
      accuratezza  precision  recall      f1
      race
Asian           0.662      0.422   0.521   0.466
Black           0.641      0.634   0.709   0.669
Hispanic        0.617      0.534   0.607   0.568
Other           0.667      0.544   0.587   0.564
White           0.670      0.517   0.592   0.552

```

Riscontriamo un divario particolarmente marcato per quanto riguarda l'attributo relativo alla disabilità: il sistema mostra una capacità di riconoscimento nettamente superiore per le persone con disabilità, che raggiungono un F1-score di 0.809, rispetto a chi ne è privo (0.471), ciò deriva però dal corretto funzionamento atteso del sistema e non da bias da correggere, in quanto si tratta dell'esistenza di programmi pubblici dedicati. Analogamente, osservando l'andamento per gruppi d'età, il modello risulta più performante nelle fasce estreme, ovvero tra i 0-17 anni e i 50-64 anni; ciò suggerisce che la capacità di generalizzazione del sistema sia fortemente influenzata dalle specifiche dinamiche di copertura che caratterizzano queste fasi della vita.

Infine, sono soprattutto i dati relativi all'appartenenza etnica che mettono in luce una forte eterogeneità, con punteggi di F1-score che oscillano significativamente, passando dallo 0.466 registrato per la categoria *Asian* fino allo 0.669 per la categoria *Black*. Tale divergenza conferma la persistenza di bias legati all'etnia, sottolineando l'urgente necessità di integrare tecniche di mitigazione avanzate -come interventi di *in-processing* o *post-processing*- per equilibrare il comportamento del classificatore e garantire una maggiore equità distributiva tra tutti i segmenti della popolazione.

Utilizzando poi il *MetricFrame* di Fairlearn, che prenderemo in analisi più avanti, analizziamo come queste performance si distribuiscano rispetto a specifici attributi sensibili: non ci limitiamo a valutare quanto il modello sia preciso, ma verifichiamo che sia giusto. Tale approccio ci consente di monitorare costantemente la presenza di potenziali *bias* algoritmici, garantendo che le nostre conclusioni siano non solo statisticamente robuste, ma anche eticamente sostenibili.

In conclusione, la regressione logistica si dimostra uno strumento eccellente per definire una solida *baseline* interpretativa. Pur riconoscendo i margini di miglioramento necessari per ottimizzare la sensibilità (Recall), il percorso intrapreso ci offre una base conoscitiva trasparente e monitorabile.

7. Metriche di fairness

Oltre a valutare le prestazioni complessive del classificatore, è stata analizzata anche la sua equità (fairness) rispetto ai principali attributi sensibili presenti nel dataset. L'obiettivo è verificare se il modello mantenga un comportamento omogeneo nei confronti dei diversi gruppi della popolazione oppure se produca risultati differenti a seconda della caratteristica considerata.


Per ciascun attributo sensibile (sex, race, disability e age_group) sono state calcolate due metriche di fairness utilizzando la libreria Fairlearn:

- **Demographic Parity Ratio**, la quale confronta la frequenza con cui il modello assegna la classe positiva ai diversi gruppi. Un valore prossimo a 1 indica che tutti i gruppi ricevono, in media, una proporzione simile di predizioni positive.
- **Equalized Odds Ratio**, la quale confronta le prestazioni del modello tra i gruppi considerando sia il tasso di veri positivi (*True Positive Rate*) sia quello di falsi positivi (*False Positive Rate*). Anche in questo caso, valori vicini a 1 indicano una maggiore uniformità del comportamento del classificatore.

Per gli attributi costituiti da più di due categorie, come *race* e *age_group*, Fairlearn calcola il rapporto tra il gruppo che ottiene il risultato meno favorevole e quello che ottiene il risultato più favorevole. Di conseguenza, quanto più il valore della metrica si avvicina a 1, tanto minori risultano le differenze tra i gruppi considerati.

8. Matrice di confusione

Per approfondire il comportamento del classificatore è stata analizzata anche la **Confusion Matrix normalizzata**, la quale mostra la percentuale di osservazioni correttamente e incorrettamente classificate all'interno di ciascuna classe reale.



Dalla matrice emerge che il modello riconosce correttamente il **69,4%** degli individui che non possiedono una copertura sanitaria pubblica, mentre il restante **30,6%** viene classificato erroneamente come appartenente alla classe positiva. Per quanto riguarda gli individui che possiedono una copertura sanitaria


pubblica, il modello identifica correttamente il **59,5%** dei casi, mentre il **40,5%** viene classificato in modo errato come privo di copertura.

Nel complesso, il classificatore mostra una maggior capacità nel riconoscere la classe negativa rispetto a quella positiva. Sebbene riesca a individuare una parte significativa degli individui con copertura sanitaria pubblica, continua a produrre un numero non trascurabile di errori, in particolare di **falsi negativi**, cioè casi in cui la presenza della copertura non viene riconosciuta. Questo risultato è coerente con il valore del **Recall**, che evidenzia come il modello non riesca ancora a identificare tutti gli individui appartenenti alla classe positiva.

La matrice di confusione conferma quindi quanto osservato attraverso le altre metriche di valutazione: il modello raggiunge prestazioni complessivamente soddisfacenti, ma presenta ancora margini di miglioramento nella capacità di distinguere correttamente tutte le osservazioni, soprattutto quelle appartenenti alla classe positiva.

9. Curva ROC e AUC

Per completare la valutazione del classificatore è stata analizzata anche la **ROC Curve (Receiver Operating Characteristic)**, che rappresenta la relazione tra il **True Positive Rate (Recall)** e il **False Positive Rate** al variare della soglia di classificazione.



Questo grafico consente di valutare la capacità del modello di distinguere correttamente gli individui appartenenti alla classe positiva da quelli appartenenti alla classe negativa.

L'area sottesa alla curva (**AUC - Area Under the Curve**) risulta pari a **0,70**: considerando che un classificatore puramente casuale avrebbe un valore di AUC pari a **0,50**, il risultato ottenuto indica che il modello possiede una discreta capacità discriminante. Pur non raggiungendo prestazioni elevate, la regressione logistica riesce a distinguere le due classi in misura significativamente migliore rispetto a una classificazione casuale.

La forma della curva conferma questo comportamento: il modello ottiene un buon compromesso tra il riconoscimento dei casi positivi e il contenimento dei falsi positivi, senza però raggiungere una separazione ottimale tra le due classi. Tale risultato è coerente con le metriche di valutazione precedentemente analizzate (Accuracy, Precision, Recall e F1-score), che evidenziano prestazioni complessivamente soddisfacenti ma ancora migliorabili.

10. Conclusioni

In conclusione, l'analisi condotta ha permesso di delineare un quadro esaustivo delle performance e delle implicazioni etiche del nostro modello di classificazione.

Sebbene il sistema abbia raggiunto una capacità discriminante discreta, confermata da un'AUC di 0,70, i risultati evidenziano una spiccata prudenza algoritmica che penalizza significativamente la sensibilità (Recall), limitando la capacità di identificare correttamente tutti i soggetti beneficiari della copertura sanitaria. Parallelamente, la valutazione dell'equità ha dimostrato che l'approccio di "fairness through blindness" si è rivelato insufficiente: la presenza di correlazioni latenti e variabili proxy ha permesso al modello di perpetuare disparità sistemiche, particolarmente evidenti nella distribuzione dell'accesso ai servizi su base etnica.

Riconosciamo quindi che tali iniquità non costituiscono semplici anomalie statistiche, bensì il riflesso di dinamiche socio-economiche strutturali. Pertanto, riteniamo che il modello debba essere inteso primariamente come uno strumento diagnostico, capace di rendere visibili e misurabili i bias presenti nei dati, piuttosto che come un sistema di decisione automatizzata autosufficiente.